

UFRBots2D: Team Description Paper CBR 2020

Higor S. de Jesus, Walber C. de Jesus, Fabrício V. de Jesus, Ejziel S. Santos,
Glendon S. dos Santos, Lucas L. R. da Silva, Matheus N. Tavares, Kevin L. dos Santos,
Paulo F. F. Rocha, João C. N. Bittencourt, André L. C. Ottoni

Centro de Ciências Exatas e Tecnológicas (CETEC),
Universidade Federal do Recôncavo da Bahia (UFRB), BA, Brasil
(e-mails: higor-sj@hotmail.com, walberjesus@hotmail.com, fabriciovellozo@gmail.com,
ejziels@gmail.com, glendon-souza@hotmail.com, lucaslopes0799@yahoo.com.br,
matheustavaresfsa@hotmail.com, kevinluis81@gmail.com,
pfabio.rocha@ufrb.edu.br, joaocarlos@ufrb.edu.br, andre.ottoni@ufrb.edu.br).

Abstract—This article introduces the UFRBots2D team. The 2D simulation category is one of the leagues studied by the UFRB Robot Football Team. In this sense, the results acquired through activities carried out by the team are presented, as well as the modeling and strategy developed through the Q-learning Reinforcement Learning algorithm..

Resumo — Este artigo apresenta o time UFRBots2D. A categoria de simulação 2D é uma das ligas estudadas pela Equipe de Futebol de Robôs da UFRB. Nesse sentido, são apresentados os resultados adquiridos ao longo de atividades realizadas pela equipe, bem como a modelagem e estratégia desenvolvida através do algoritmo de Aprendizado por Reforço Q-learning.

I. INTRODUÇÃO

A equipe UFRBots é um projeto de pesquisa desenvolvido na Universidade Federal do Recôncavo da Bahia (UFRB). O time iniciou suas atividades após a palestra "Futebol de Robôs: uma plataforma para o desenvolvimento de ciência e tecnologia", ministrada pelo Prof. André Luiz Carvalho Ottoni, em outubro de 2018.

Os membros da UFRBots são estudantes e professores de graduação dos cursos: Bacharelado em Engenharia Elétrica, Computação, Mecânica e do Bacharelado em Ciências exatas e Tecnológicas. Dessa maneira, cada integrante desempenha um papel específico dentro da equipe, no que compreende as duas categorias trabalhadas até o momento: *IEEE Very Small Size Soccer* (VSSS) e *RoboCup Simulation Soccer 2D*.

Organizada pela *Robocup*, a competição da categoria de Simulação 2D promove o desenvolvimento de técnicas de inteligência artificial, destinadas a aplicações para a robótica, dentro de um ambiente multiagente. Nesse contexto, a equipe já desempenhou atividades utilizando o Aprendizado por Reforço (AR), Lógica Fuzzy e Algoritmos Genéticos. Inicialmente, os estudos foram direcionados através do time base *UvA Trilearn* [6] e em seguida, dedicado a realização da competição, a utilização do *HeliosBase* (time base do *Agent2D*) [2].

Concomitante aos estudos associados a categoria de Simulação 2D, a UFRBots pôde alcançar excelentes resultados através de sua aplicação no ambiente educacional, sendo

eles: um projeto de extensão [5], um seminário de robótica [5], uma interface gráfica para o ensino do AR [10].

O projeto de extensão intitulado "UFRBots: uma visão extensionista para o futebol de robôs no Recôncavo da Bahia", teve como objetivo principal estimular o interesse pelas ciências exatas através do futebol de robôs, do qual participaram estudantes da rede pública de ensino da cidade de Cruz das Almas-Bahia e dos cursos de graduação Bacharelado em Ciências Exatas e Tecnológicas, Engenharia de Computação e Elétrica da UFRB. Onde foi produzido um material didático de apoio, um minicurso de programação básica e uso do simulador da categoria de Simulação 2D, além de uma competição entre as equipes formadas durante o período das aulas. Essa competição foi realizada junto ao "I Seminário de Robótica da UFRB", outra importante atividade realizada pela equipe, que promoveu palestras e atividades associadas a robótica.

O desenvolvimento de uma Interface Gráfica Didática para o Ensino de Aprendizado por Reforço com Futebol de Robôs, é dedicado a trabalhar com a categoria de simulação 2D, onde os usuários podem aplicar os conceitos do AR através de diferentes combinações de parâmetros do algoritmo *Q-learning*. Essas atividades, culminaram no desenvolvimento de três artigos: Desenvolvimento de uma Interface Gráfica Didática para o Ensino de Aprendizado por Reforço com Futebol de Robôs [10], Metodologia Extensionista para o Ensino de Futebol de Robôs [5] e Uma Revisão sobre Tecnologias Aplicadas ao Futebol de Robôs [9], dos quais receberam aprovação no XXIII Congresso Brasileiro de Automática (CBA) 2020.

O objetivo principal deste TDP é apresentar a descrição do time UFRBot2D. Nesse aspecto, são abordados fundamentos da modelagem do Aprendizado por Reforço (AR), no domínio do futebol de robôs em duas dimensões (2D). Além disso, são apresentados alterações e avanços nos resultados em relação aos times base adotados: *agent2D* [2] e *UFSJ2D* [8].

Este trabalho está organizado em seções. Na seção II são apresentados os conceitos básicos relacionados ao AR.

A seção III apresenta um módulo da interface gráfica desenvolvida, do qual é destinado a trabalhar com o AR. A descrição dos times bases utilizados nos estudos da categoria de Simulação 2D, está presente na seção IV. Em seguida, as estratégias básicas desenvolvidas na construção do time na seção V, bem como os resultados alcançados na seção VI. Por conseguinte, na seção VII são apresentadas as conclusões.

II. APRENDIZADO POR REFORÇO

A teoria dos Processos de Decisão de Markov, do inglês *Markov Decision Processes* (MDP), expressa uma modelagem de estados, ações, recompensas e transição de estados, que está inteiramente ligado ao AR. Os estados e ações são definidos de acordo com a política de decisão, onde é retornada uma recompensa a partir da execução de uma ação em seu estado atual e no estado futuro. Acontecendo o aprendizado, a medida que as ações vão sendo executadas e as recompensas vão sendo melhor estimadas [12].

Para trabalhar com essa política de decisão, o AR dispõe de alguns algoritmos, tais como: *Q-learning* [13] e o SARSA [12]. O *Q-learning* possui vasta utilização, não somente dentro do contexto do futebol de robôs [1], [11], [7], [10]. A Equação (1), representa a política de atualização da matriz de aprendizado Q, para cada par estado e ação. Essa matriz possui dimensão definida de acordo com número de estados, que define a quantidade de linhas da matriz, e o número de ações, que define o número de colunas, de modo que cada posição representa um valor estimado de acordo com as recompensas recebidas.

$$Q_{t+1} = Q_t(s, a) + \alpha[r + \gamma \max_{a'} Q(s_{t+1}, a_t) - Q_t(s, a)] \quad (1)$$

Os termos da Equação (1) representam: Q_{t+1} o valor da matriz atualizado após uma nova recompensa; $Q_t(s, a)$ é o valor atual da tabela para um par estado e ação (s, a); α é a taxa de aprendizado, r é a recompensa imediata recebida; γ é o fator de desconto; e $\max_{a'} Q(s_{t+1}, a_t)$ é o valor mais estimado do estado futuro. O Algoritmo 1, apresenta o funcionamento do *Q-learning*, durante o aprendizado, de acordo com a política *ε-greedy*, que define uma porcentagem de aleatoriedade na escolha das ações.

Algoritmo 1 *Q-learning*

Inicialize $Q(s_t, a_t) = 0$ para todos os pares (s_t, a_t)

while o critério de parada não é satisfeito **do**

 Observe o estado s_t

 Selecione a_t de acordo com a política *ε-greedy*

 Execute a ação a_t

 Receba a recompensa $r(s_t, a_t)$

 Observe o estado s_{t+1}

 Atualize $Q(s_t, a_t)$ de acordo com a Equação (1)

$s_t \leftarrow s_{t+1}$

end




Fig. 1. Interface Gráfica para o ensino de Aprendizado por Reforço com Futebol de Robôs

III. INTERFACE GRÁFICA PARA O ENSINO DO APRENDIZADO POR REFORÇO

A interface gráfica, possui o objetivo principal de promover a prática dos conceitos do AR, com a utilização do simulador da categoria de Simulação 2D, sua elaboração proporcionou a construção de um dos artigos aceitos no CBA 2020 [10]. Em sua construção, o sistema possui dois módulos principais: o primeiro destinado a comunicação com o simulador da *Robocup*, para trabalhar com as diretivas necessárias à execução das partidas, e o segundo módulo destinado a exibição das informações para o usuário, como controle das partidas e experimentos de AR.

A Figura 1, exibe as quatro telas principais destinadas a trabalhar com o AR, sendo elas:

- 1 - Exibe a interface inicial do sistema com acesso as telas: Nova Partida (destinada a realizar uma partida entre dois times quaisquer); Aprendizado (parte destinada a executar experimentos com o AR); Assistir Partidas (tela que acessa os arquivos de registro das partidas, permitindo assisti-las novamente através do *LogPlayer* [3]); Tutorial (parte destinada a exemplificar o uso do sistema); Sobre (informações inerente ao sistema e dos envolvidos em sua construção);
- 2 - Tela exibida ao acessar opção *Aprendizado* na tela 1. Essa etapa permite o usuário cadastrar, remover ou acessar os dados inerentes a um experimento, permitindo o agrupamento de ensaios do AR para determinadas finalidades.
- 3 - Selecionando um experimento na tela 2 e clicando no botão *Dados* (botão azul), são exibidos os resultados armazenados para cada experimento, agrupados por média de acordo com a combinação dos parâmetros: Fator de Desconto; Taxa de Aprendizado; Número de episódios; Política de aleatoriedade ϵ -greedy. Essa etapa permite a plotagem de um gráfico com as médias gerais por combinação de saldo de gols, gols feitos e gols sofridos de acordo com a tabela disposta na parte superior. Os ensaios individuais, são descritos na tabela logo abaixo, onde ao selecionar uma opção é possível deletar (botão vermelho) ou ver as informações desse ensaio (botão azul), onde são plotados os gráficos de gols feitos, gols sofridos e saldo de gol, além da exibição de três arquivos de texto com os valores de partida para cada episódio, com o intuito de facilitar a análise dos resultados em ferramentas externas.
- 4 - Ao selecionar um experimento na tela 2, é feito um redirecionamento para a tela de configurações de um novo ensaio. O usuário define: o número de episódios, taxa de aprendizado, fator de desconto e política ϵ -greedy formando assim uma combinação de parâmetros. Além de escolher o algoritmo a ser usado, tendo disponível até o momento da escrita desse trabalho apenas o *Q-learning*, a utilização de uma matriz nova ou continuar com a usada anteriormente em outros ensaios, a ativação ou não do monitor para assistir as partidas e se o sistema deve compilar os arquivos do time.

IV. TIMES BASE

A construção do time UFRBots2D, se deu com a utilização de três times base: *Uva Trilearn* [6], *HeliosBase* (time base do *Agent2D*) [2] e *UFSJ2D*. O *Uva Trilearn* é o time desenvolvido pelo *Intelligent Autonomous Systems Group* (IAS) da Universidade de Amsterdam, utilizado nas etapas iniciais de estudo e aplicação inicial do AR. Sua utilização também foi realizada no projeto de extensão, onde estudantes da graduação e ensino médio aprenderam a criar suas variações de times, bem como aplicada na interface gráfica citada na Seção III.

No segundo momento, no sentido de participar de competições, houve a inclusão do uso do time UFSJ2D que tem como base em sua construção o *HeliosBase*. O UFSJ2D é um time da Universidade Federal de São João del-Rei, do qual participou do campeonato mundial em 2014 alcançando a 8ª posição [8]. Em sua modelagem, o AR foi utilizado para definir as estratégias de posse de bola. Além disso, adotou Lógica Fuzzy para estratégias sem posse de bola.

V. MODELAGEM DO APRENDIZADO POR REFORÇO

A modelagem adotada para desenvolvimento do time teve como base os Processos de Decisão de Markov, a partir do Aprendizado por Reforço. As próximas subseções retratam a política de decisão para os estados, ações e recompensas, tomando como base o comportamento dos agentes (jogadores) inseridos no ambiente (campo), com base na utilização do time UFSJ2D [8].

A. Modelagem das Ações

As definições das ações, são expressas de acordo com a posse de bola do agente, nesse sentido a principal diferença da UFRBots2D em relação ao time UFSJ2D se concentra na região de defesa, da qual ação a ser executada pelo agente depende da proximidade do adversário. Tomando como base esse comportamento, são utilizadas as seguintes ações:

- Ação: Chute - o agente executa um chute em direção ao gol adversário;
- Ação: Lançamento - é feito um lançamento de bola em direção a área de ataque;
- Ação: Passe 1 - é realizado um passe do tipo 1 para outro agente do mesmo time;
- Ação: Passe 2 - é realizado um passe do tipo 2 para outro agente do mesmo time;
- Ação: Drible 1 - o agente executa um drible do tipo 1;
- Ação: Drible 2 - o agente executa um drible do tipo 2.

B. Modelagem dos Estados

A modelagem dos estados consiste na área de ataque, considerando o avanço do time em campo da esquerda para a direita. Essa divisão foi realizada em seções (A, B, C, D e E) de acordo com esse avanço. Cada seção possui três subdivisões, exceto a seção E com quatro. As coordenadas X e Y são utilizadas para definir cada divisão de estado. Essa modelagem se difere do time UFSJ2D em dois sentidos. O primeiro é na quantidade de seções que aumentou para cinco, com a inclusão da Seção E. Já a segunda alteração, se destaca

como a mais relevante, se baseia nos estados próximos ao gol adversário, que se concentra em determinar o avanço do time não somente da esquerda para a direita, mas também em convergir esse movimento em direção ao gol no eixo Y, com a inclusão dos estados auxiliares 14 e 16. A Figura 2 apresenta essa configuração.




Fig. 2. Divisão do ambiente em estados e seções. Modelagem que considera o avanço do time da esquerda para direita

Além da divisão de acordo com as coordenadas, é feita uma verificação de proximidade dos oponentes, dividindo dessa forma cada estado em dois estados secundários, sendo esses: o primeiro com oponente com distância menor que quatro, considerado assim próximo, e outro distante. Totalizando 34 estados para o campo de ataque. Essa mesma verificação é realizada na área de defesa, que apesar de não ter sido cenário de aplicação do AR, possui uma grande relevância no rendimento do time.

C. Modelagem dos Reforços

A modelagem dos reforços tem como objetivo acelerar o aprendizado dos agentes, tendo como base duas primícias: a teoria MDP, de acordo com a política de decisão e a modelagem dos estados, a qual se baseia no avanço do time em direção ao gol adversário. Dessa maneira, ao executar uma ação o agente recebe uma penalidade ou recompensa, quando mantém ou não a posse de bola. Esses valores variam de acordo com as seções da modelagem de estados (Figura 2).

A Tabela I exhibe os valores definidos para cada seção. Todavia, o estado 15 possui uma particularidade em seu valor de recompensa, por ser considerada a região mais crítica do ataque.

VI. RESULTADOS

Procurou-se com este trabalho a evolução do time UFRBots2D, com relação ao time base utilizado, UFSJ2D. Para

TABLE I
TABELA DE RECOMPENSAS E PENALIDADES, DE ACORDO COM A
MODELAGEM DAS SEÇÕES.

Seção	Penalidade	Recompensa
A	-10	-1
B	-1	0
C	0	1
D	1	10
E	10	20
E (Estado 15)	10	40

isso, a partir da modelagem da política de decisão (estados, recompensas e ações) foram simuladas partidas entre os times UFRBots2D e UFSJ2D, adotando o time base do HeliosBase (time base do Agent2D) como adversário.

Foram realizadas 10 partidas para cada time analisado (UFRBots2D e UFSJ2D), sendo armazenadas as seguintes métricas: gols feitos (GF), gols sofridos (GS) e o saldo de gols (SG). Dessa maneira, foram elaboradas 2 tabelas: a Tabela II com os resultados das partidas entre UFRBots2D e HeliosBase, e a Tabela III com relação das partidas entre UFSJ2D e HeliosBase.

TABLE II
RESULTADOS DAS PARTIDAS ENTRE UFRBOTS2D X HELIOSBASE

UFRBots2D		
Gols Feitos	Gols Sofridos	Saldo de Gols
5	0	5
2	1	1
5	2	3
1	0	1
2	1	1
5	0	5
1	0	1
4	0	4
2	0	2
4	1	3

TABLE III
RESULTADOS DAS PARTIDAS ENTRE UFSJ2D X HELIOSBASE

UFSJ2D		
Gols Feitos	Gols Sofridos	Saldo de Gols
4	1	3
3	1	2
2	0	2
3	1	2
2	1	1
2	0	2
4	2	2
4	0	4
1	1	0
0	0	0

Com base nos resultados expressos nas Tabelas II e III, os dados foram analisados de acordo com o desempenho geral dos times, sendo definidas métricas de acordo com a soma dos resultados das partidas. A Tabela IV resume as medidas de desempenho para UFRBots e UFSJ2D.

As medidas de desempenho GF, GS e SG apresentam os melhores resultados para o time UFRBots2D, com destaque

TABLE IV

TOTAL DE GF (GOLS FEITOS), GS (GOLS SOFRIDOS) E SG (SALDO DE GOLS) PARA OS TIMES UFRBOTS2D E UFSJ2D.

TIME	GF	GS	SG
UFRBots2D	31	5	26
UFSJ2D	25	7	18

para o SG, que possui uma diferença de 8 gols no rendimento geral do time. Os resultados alcançados pelo time UFRBots2D, são relevantes para evidenciar uma evolução do time quando comparado ao UFSJ2D, pelo fato do mesmo já ter alcançado a 8ª posição no campeonato mundial de 2014.

VII. CONCLUSÃO

Este trabalho teve como objetivo principal apresentar a descrição do time UFRBots2D. Além disso, descrever a estratégia de aprendizado por reforço, tendo como base o time UFSJ2D. Para isso, foram aplicadas as modelagens de estado, ação e recompensas.

O time UFRBots2D desenvolvido, apresentou uma evolução a partir dos resultados em relação ao UFSJ2D. Ressalta-se que o UFRBots2D alcançou com uma diferença de oito gols para a métrica de saldo de gols (SG), a qual expressa o rendimento total do time.

Em trabalhos futuros espera-se a evolução do time UFRBots2D, a partir da implementação de outros algoritmos de AR dentro da colaboração multiagente. Além disso, descrever a aplicação de outras técnicas de Inteligência Artificial no futebol 2D.

AGRADECIMENTOS

Este trabalho foi desenvolvido dentro do contexto do projeto de pesquisa "UFRBots: Equipe de Futebol de Robôs da UFRB", com apoio dessa instituição, código de projeto 2372, PPGCI/UFRB. Além disso, agradecemos aos desenvolvedores e instituições dos times base utilizados: *Uva Trilearn*, *Helios Base* e *UFSJ2D*.

REFERENCES

- [1] AHUMADA, Gabriel A.; NETTLE, Cristóbal J.; SOLIS, Miguel A. Accelerating Q-learning through Kalman filter estimations applied in a RoboCup SSL simulation. In: 2013 Latin American Robotics Symposium and Competition. IEEE, 2013. p. 112-117.
- [2] AKIYAMA, Hidehisa; NAKASHIMA, Tomoharu. Helios base: An open source package for the robocup soccer 2d simulation. In: Robot Soccer World Cup. Springer, Berlin, Heidelberg, 2013. p. 528-535.
- [3] CHEN, Mao et al. Robocup soccer server. Manual for Soccer Server Version, v. 7, 2001.
- [4] JESUS, H. S.; OTTONI, A. L. C. Desenvolvimento de uma Interface Gráfica Didática para o Ensino de Aprendizado por Reforço com Futebol de Robôs. XXIII Congresso Brasileiro de Automática de Automática (CBA), 2020.
- [5] JESUS, H. S.; JESUS, J. A. M. P.; SANTOS, A.; OTTONI, A. L. C.; BITTENCOURT, J. C. N.; ROCHA, P. F. F. Metodologia Extensionista para o Ensino de Futebol de Robôs. XXIII Congresso Brasileiro de Automática de Automática (CBA), 2020.
- [6] KOK, Jelle R. et al. UvA Trilearn 2003 team description. Proceedings CD RoboCup, v. 2003, 2003.

- [7] LIMA JÚNIOR, Francisco Chagas de. Algoritmo Q-learning como estratégia de exploração e/ou exploração para metaheurísticas GRASP e algoritmo genético. 2009. 140 f. Tese (Doutorado em Automação e Sistemas; Engenharia de Computação; Telecomunicações) - Universidade Federal do Rio Grande do Norte, Natal, 2009.
- [8] OTTONI, Andre Luiz C. et al. UFSJ2D (UaiSoccer2D + RoboCap): Team Description Paper Robocup 2014.
- [9] OTTONI, Andre Luiz C. et al. Uma Revisão sobre Tecnologias Aplicadas ao Futebol de Robôs. XXIII Congresso Brasileiro de Automática de Automática (CBA), 2020.
- [10] OTTONI, André Luiz Carvalho; NEPOMUCENO, Erivelton Geraldo; DE OLIVEIRA, Marcos Santos. Development of a Pedagogical Graphical Interface for the Reinforcement Learning. IEEE Latin America Transactions, v. 18, n. 01, p. 92-101, 2020.
- [11] SILVA, Isaac J. et al. Using reinforcement learning to improve the stability of a humanoid robot: Walking on sloped terrain. In: 2015 12th Latin American Robotics Symposium and 2015 3rd Brazilian Symposium on Robotics (LARS-SBR). IEEE, 2015. p. 210-215.
- [12] SUTTON, Richard S.; BARTO, Andrew G. Reinforcement learning: An introduction. MIT press, 2018.
- [13] WATKINS, Christopher JCH. Technical note q-learning. Reinforcement learning, 1993.