

UFRBots2D: Team Description Paper CBR 2022

Gleice K. B. Souza¹, Lais C. de Medeiros², Victória Emanuela A. Oliveira³,
João C. N. Bittencourt⁴, Paulo F. F. Rocha⁵ e André L. C. Ottoni⁶

Abstract—This article introduces the UFRBots2D team for the Brazilian Robotics Competition 2022. The 2D simulation category is one of the leagues studied by the UFRB Robot Football Team. In this sense, the results acquired through activities carried out by the team are presented, as well as the modeling and strategy developed through the Q-learning Reinforcement Learning algorithm. The new results here in presented are based on the comparison of performance in relation to the performance observed in CBR 2021.

Resumo — Este artigo apresenta o time UFRBots2D para a participação na Competição Brasileira de Robótica 2022. A categoria de simulação 2D é uma das ligas estudadas pela Equipe de Futebol de Robôs da UFRB. Nesse sentido, são apresentados os resultados adquiridos ao longo de atividades realizadas pela equipe, bem como a modelagem e estratégia desenvolvida através do algoritmo de Aprendizado por Reforço Q-learning. Os novos resultados apresentados pelo time, tem como premissa o comparativo de rendimento em relação ao desempenho observado na CBR 2021.

I. INTRODUÇÃO

A UFRBots é a equipe de futebol de robôs da Universidade Federal do Recôncavo da Bahia (UFRB), sendo constituída por discentes e docentes dos cursos de Bacharelado em Ciências Exatas e Tecnológicas (BCET), Engenharia de Computação, Engenharia Mecânica e Engenharia Elétrica. Criada em 2018, a UFRBots tem como objetivo promover e estimular a robótica através do futebol de robôs, desenvolvendo atividades de ensino, pesquisa e extensão. Atualmente, a equipe possui atuação em duas categorias distintas: *IEEE Very Small Size Soccer (VSSS)* e a *RoboCup Simulation Soccer 2D*.

A categoria de futebol de robôs 2D [6] possui o intuito de promover o estudo e desenvolvimento de técnicas de Inteligência Artificial e *Machine Learning* direcionadas para ambientes multiagentes. Com isso, o desenvolvimento dessas técnicas permite o progresso tecnológico na robótica e em suas diversas aplicações.

Durante o processo de desenvolvimento do time UFRBots2D para a Competição Brasileira de Robótica (CBR) 2022, foram utilizados os seguintes times bases: *Uva Trilearn* [7], *HeliosBase* (time base do Agent2D) [2] e *UFSJ2D* [10]. A partir da utilização desses times base, o UFRBots2D participou da Competição Brasileira de Robótica em 2020

e em 2021. Em 2020 o time alcançou a 8º posição e em 2021 o time conseguiu um grande avanço, alcançando a 4º posição. Em seu projeto, o UFRBots2D contou com a aplicação do AR para o desenvolvimento de estratégias de posse de bola. Neste sentido, na competição do ano de 2022 a equipe continuará o desenvolvimento sobre o time base utilizado no ano anterior.

Destaca-se também a atuação da equipe UFRBots na realização de projetos de extensão envolvendo o ensino de robótica atrelado a Simulação 2D e Inteligência Artificial. Essas atividades possibilitam aplicar os conhecimentos adquiridos e fomentar o interesse da comunidade acadêmica nas áreas ciências exatas e engenharias com o uso de futebol de robôs. Por exemplo, em 2021 foi realizada a *UFRBots Week* em formato virtual. Esse evento contou palestras e mesas redondas sobre a área de robótica e também uma pequena competição de futebol de robôs.

Dessa forma, o objetivo deste trabalho é apresentar a descrição do time UFRBots2D para a participação na Competição Brasileira de Robótica 2020. Para isso, são apresentados aspectos dos projetos desenvolvidos. Além disso, são mostrados detalhes da estratégia proposta de Inteligência Artificial usando Aprendizado por Reforço. Também espera-se destacar os avanços no desempenho do times em relação às duas primeiras participação na CBR.

Na Seção II, são apresentados os principais projetos desenvolvidos pela UFRBots. Na Seção III, são abordados conceitos relacionados ao Aprendizado por Reforço e explicações sobre o algoritmo Q-learning. Na Seção IV, são apresentados os times utilizados como base, o time utilizado na última competição em que a equipe participou e as técnicas aplicadas. Na Seção V, é detalhada a modelagem do Aprendizado por Reforço, sendo estas a modelagem das ações, a modelagem dos estados e a modelagem dos reforços, utilizadas no desenvolvimento do UFRBots2D. Na Seção VI, é apresentado os principais resultados obtidos. Por fim, na Seção VII são apresentadas as conclusões dos resultados obtidos e o planejamento futuro do time, seguido pelos agradecimentos e referências.

II. PROJETOS E PUBLICAÇÕES

Além do desenvolvimento dos times para a competição, a UFRBots também esteve empenhada em um grande número de estudos e comunicações técnicas. Com isso, a equipe acumulou um conjunto de materiais como os citados a seguir:

- Uma Revisão sobre Tecnologias Aplicadas ao Futebol de Robôs - Artigo publicado no Congresso Brasileiro de Automática - CBA 2020 [11].

¹Gleice K. B. Souza, kelly.189@hotmail.com

²Lais C. de Medeiros, lalaicardoso27@hotmail.com

³Victória E. A. Oliveira, alves.victoria.e@gmail.com

⁴João C. N. Bittencourt, joaocarlos@ufrb.edu.br

⁵Paulo F. F. Rocha, pfabio.rocha@ufrb.edu.br

⁶André L. C. Ottoni, andre.ottoni@ufrb.edu.br

* Centro de Ciências Exatas e Tecnológicas, Universidade Federal do Recôncavo da Bahia, Cruz das Almas, BA, Brasil

- Metodologia Extensionista para o Ensino de Futebol de Robôs - Artigo publicado no Congresso Brasileiro de Automática - CBA 2020 [4].
 - Material produzido durante o projeto: Apostila de ensino e utilização da Categoria de Simulação 2D.
- Desenvolvimento de uma Interface Gráfica Didática para o Ensino de Aprendizado por Reforço com Futebol de Robôs - Artigo publicado no Congresso Brasileiro de Automática - CBA 2020 [5].
- Metodologia Extensionista para o Ensino de Sistemas Microcontrolados. - Resumo expandido publicado no Congresso Brasileiro de Extensão Universitária [16].
- Metodologia extensionista para o ensino virtual de Inteligência Artificial e robótica em ambientes virtuais de aprendizagem - Artigo aprovado no Congresso Brasileiro de Educação em Engenharia - COBENGE 2022.
- ITUBERÁBots: uma visão extensionista para o futebol de robôs no baixo Sul da Bahia - Artigo aprovado no Congresso Brasileiro de Educação em Engenharia - COBENGE 2022.

III. APRENDIZADO POR REFORÇO

Os Processos de Decisão de Markov, do inglês *Markov Decision Process* (MDP), são processos caracterizados por tomadas de decisões onde os resultados das ações são probabilísticos, ou seja, o resultado de uma ação é incerto até que a mesma seja realizada. As situações que podem ser modeladas pelo MDP contam com uma tupla de estados, ações, recompensas e uma função probabilística, na qual esta tupla poderá ser utilizada para caracterizar e consequentemente resolver o problema [14].

Neste sentido, o MDP pode ser utilizado para descrever o Aprendizado por Reforço (AR) [1], [3], [13]. O AR, é uma forma de Aprendizado de Máquina na qual o agente irá aprender a medida que interage com o ambiente. Neste, o mesmo irá realizar ações e receberá reforços que podem indicar que a ação realizada ocasionou em sucesso ou fracasso. No entanto, o agente não sabe previamente o resultado da ação até que esta seja realizada [17].

O AR possui diversos algoritmos, sendo que os mais conhecidos são o *Q-learning* [19], [18] e o Sarsa [17]. Ambos os algoritmos se baseiam no método de Diferença Temporal, no qual as respostas obtidas serão dadas de acordo com os acontecimentos entre estados consecutivos [15], [17]. A Equação 1 apresentada a seguir trata-se da função de atualização do algoritmo *Q-learning*:

$$Q_{t+1} = Q_t(s, a) + \alpha[r + \gamma \max_{a'} Q(s', a') - Q_t(s, a)] \quad (1)$$

na qual, Q representa a matriz de aprendizado; r representa o reforço recebido; α é a taxa de aprendizado; γ é o fator de desconto; s é o estado atual; a é a ação atual; s' é o estado futuro; e a' é a ação futura. O Algoritmo 1 apresenta o *Q-learning*.

Algoritmo 1 *Q-learning*

```

Inicialize  $Q(s_t, a_t) = 0$  para todos os pares  $(s_t, a_t)$ 
while o critério de parada não é satisfeito do
  Observe o estado  $s_t$ 
  Selecione  $a_t$  de acordo com a política  $\epsilon$ -greedy
  Execute a ação  $a_t$ 
  Receba a recompensa  $r(s_t, a_t)$ 
  Observe o estado  $s_{t+1}$ 
  Atualize  $Q(s_t, a_t)$  de acordo com a Equação (1)
   $s_t \leftarrow s_{t+1}$ 
end

```

O algoritmo *Q-learning* conta com os parâmetros de taxa de aprendizado e fator de desconto. A taxa de aprendizado pode variar entre 0 e 1, este parâmetro irá controlar a o quanto as atualizações irão influenciar na matriz de aprendizado [12]. Já o fator de desconto, é o parâmetro que irá controlar o quão importante é uma recompensa recebida pelo agente. Assim como a taxa de aprendizado, o fator de desconto também varia entre 0 e 1 [8]. Os algoritmos de AR podem contar ainda com a política ϵ -greedy, este parâmetro irá controlar o nível de aleatoriedade das ações tomadas pelo agente. Assim como os demais, este parâmetro também varia entre 0 e 1 [8], [9].

IV. TIMES BASE

O time UFRBots2D foi desenvolvido a partir de três times base:

- *Uva Trilearn* [7];
- HeliosBase (time base do Agent2D) [2];
- UFSJ2D [10].

O *Uva Trilearn* foi desenvolvido pelo *Intelligent Autonomous System Group* (IAS) da Universidade de Amsterdam. Esse time foi utilizado no início das aplicações do AR e nas etapas iniciais de estudo. Já o time UFSJ2D, é um time que possui como base o HeliosBase. O UFSJ2D foi desenvolvido pela Universidade Federal de São João del-Rei aplicando Aprendizado por Reforço para participação no mundial da *RoboCup* 2014.

V. MODELAGEM DO APRENDIZADO POR REFORÇO

A modelagem adotada para desenvolvimento do time teve como base os Processos de Decisão de Markov, a partir do Aprendizado por Reforço. As próximas subseções retratam a política de decisão para os estados, ações e recompensas, tomando como base o comportamento dos agentes (jogadores) inseridos no ambiente (campo), com base na utilização do time UFSJ2D [10].

A. Modelagem das Ações

As definições das ações, são expressas de acordo com a posse de bola do agente. Nesse sentido a principal diferença da UFRBots2D em relação ao time UFSJ2D está na região de defesa, na qual ação a ser executada pelo agente depende da proximidade do adversário. Tomando como base esse comportamento, são utilizadas as seguintes ações:

As definições das ações, são expressas de acordo com a posse de bola do agente, nesse sentido as diretrizes se escolha das ações se baseiam no estado, região de defesa ou ataque e a proximidade do adversário. Tomando como base esse comportamento, são utilizadas as seguintes ações:

- Ação: Chute - o agente executa um chute em direção ao gol adversário;
- Ação: Lançamento - é feito um lançamento de bola em direção a área de ataque;
- Ação: Passe 1 - é realizado um passe do tipo 1 para outro agente do mesmo time;
- Ação: Passe 2 - é realizado um passe do tipo 2 para outro agente do mesmo time;
- Ação: Drible 1 - o agente executa um drible do tipo 1;
- Ação: Drible 2 - o agente executa um drible do tipo 2.

B. Modelagem dos Estados

A modelagem dos estados possui enfoque na região de ataque do time, considerando o avanço do mesmo em direção ao gol adversário (da esquerda para a direita). Na competição da CBR 2020, o time adotou uma divisão em 5 seções (A, B, C, D e E). Já a versão de 2021 passou por uma série de atualizações e estas foram mantidas na versão de 2022. As modificações citadas anteriormente podem ser vistas na Figura 1, dentre as quais destacam-se: as três primeiras seções foram unificadas; a penúltima seção (B) obteve a entrada de dois estados emergentes (E), os quais são utilizados como situação de chute ao gol quando o passo ou drible estão em condições ruins; e a última seção (C), em seus estados auxiliares (08 e 10), possuem também um comportamento emergente para o chute ao gol.




Fig. 1. Divisão do ambiente em estados e seções. Modelagem que considera o avanço do time da esquerda para direita

As coordenadas X e Y são utilizadas para definir cada divisão de estado. Contudo, além disso, é realizada uma

Tabela I: Recompensas e Penalidades.

Seção	Penalidade	Recompensa
A	-10	-1
B	-1	20
C (Estado 09)	10	40

verificação de proximidade dos oponentes, dividindo cada estado em dois: o primeiro com oponente que apresenta distância menor que quatro, considerado assim próximo, e outro distante. Ao todo foram implementados 22 estados para o campo de ataque. Essa mesma verificação é realizada na área de defesa, que, apesar de não ter sido cenário de aplicação do AR, possui uma grande relevância no rendimento do time.

C. Modelagem dos Reforços

A modelagem dos reforços tem como objetivo acelerar o aprendizado dos agentes, tendo como base duas primícias: a teoria MDP, de acordo com a política de decisão e a modelagem dos estados, a qual se baseia no avanço do time em direção ao gol adversário. Dessa maneira, ao executar uma ação o agente recebe uma penalidade ou recompensa, quando mantém ou não a posse de bola. Esses valores variam de acordo com as seções da modelagem de estados (Figura 1).

A Tabela I exhibe os valores definidos para cada seção. Todavia, o Estado 09 possui uma particularidade em seu valor de recompensa, quando comparado aos demais estados na mesma seção, por ser considerada a região mais crítica do ataque.

VI. RESULTADOS

Um dos objetivos deste trabalho é apresentar a evolução do time atual da UFRBots2D em relação aquele utilizado na competição do ano passado (2021). Para isto, foram simuladas partidas entre o UFRBots2D e diversos times. Dentre os times utilizados, encontram-se os seguintes times participantes da CBR 2020:

- FUTVASF2D
 - Instituição: Universidade Federal do Vale do São Francisco.
 - Classificação: Segundo colocado.
- Bullrussia2020
 - Instituição: Instituto Nacional de Telecomunicações.
 - Classificação: Sexto colocado.
- Robotbulls
 - Instituição: Instituto Nacional de Telecomunicações.
 - Classificação: Sétimo colocado.

Para este experimento, foram realizadas 10 partidas sequenciais contra cada time selecionado. Além disso, para realizar uma melhor comparação, também foram realizadas partidas entre os times selecionados e o time utilizado na CBR 2021. Neste cenário, também foram realizadas 10 partidas sequenciais contra cada time. A partir dos resultados

obtidos foram analisados os seguintes critérios: quantidade de gols marcados (GM), quantidade de gols sofridos (GS) e o saldo de gols (SG). Os dados apresentados a seguir foram obtidos a partir dos resultados dessas partidas e apresentam os critérios avaliados.

As Tabelas II e III, apresentam os resultados obtidos nas partidas simuladas que foram realizadas contra o time Futvasf2D. Especificamente, a Tabela II exibe os resultados das partidas entre o time UFRBots2D-2022 e o time Futvasf2D. Enquanto a Tabela III, por sua vez, apresenta os resultados das partidas entre o time UFRBots2D-2021 e o time Futvasf2D.

Tabela II: Resultados das partidas entre UFRBots2D-2022 X Futvasf2D.

UFRBots	Futvasf2D	SG
1	0	1
1	1	0
0	1	-1
1	0	1
3	0	3
1	2	-1
1	0	1
2	0	2
1	0	1
0	0	0
11	4	7

Tabela III: Resultados das partidas entre UFRBots2D-2021 X Futvasf2D.

UFRBots	Futvasf2D	SG
1	1	0
1	0	1
1	1	0
2	1	1
0	0	0
1	0	1
1	1	0
1	2	-1
0	0	0
1	1	0
9	7	2

A partir da Tabela II, pode-se observar que das 10 partidas realizadas a UFRBots obteve apenas 2 derrotas e 2 empates contabilizando assim 6 vitórias. Além de ter apresentado um saldo de gols positivo. Analisando a Tabela III e realizando uma comparação com os resultados apresentados na Tabela II, é possível verificar que dentre as 10 partidas realizadas o time UFRBots2D-2021 obteve apenas 3 vitórias. O time ainda apresentou 6 empates e 1 derrota contra o time Futvasf2D, resultando em um número positivo de saldo de gols menor.

Dando seguimento as análises, as Tabelas IV e V, apresentam os resultados obtidos nas partidas simuladas realizadas contra o time Bullrussia2020. Especificamente, a Tabela IV apresenta os resultados das partidas entre o time UFRBots2D (2022) e o time Bullrussia2020. Por outro lado, a Tabela V, exibe os resultados das partidas entre o time UFRBots2D (2021) e o time Bullrussia2020.

Tabela IV: Resultados das partidas entre UFRBots2D-2022 X Bullrussia2020.

UFRBots	Bullrussia2020	SG
1	1	0
2	0	2
3	1	2
0	1	-1
0	0	0
0	0	0
1	3	-2
0	0	0
0	0	0
0	0	0
7	6	1

Tabela V: Resultados das partidas entre UFRBots2D-2021 X Bullrussia2020.

UFRBots	Bullrussia2020	SG
0	1	-1
0	0	0
3	1	2
1	1	0
0	0	0
0	0	0
0	2	-2
1	3	-2
0	1	-1
0	0	0
5	9	-4

A partir do resultado em saldo de gols positivo, pode-se observar na Tabela IV, que apenas 2 partidas foram perdidas, o UFRBots ainda conseguiu 2 vitórias e 6 empates. Observando a Tabela V e analisando seu conteúdo em relação aos resultados apresentados na Tabela IV, percebe-se que, das 10 partidas realizadas, o time UFRBots2D-2021 conseguiu obter apenas uma vitória. Com isso, foram obtidos resultado 5 empates e 4 derrotas, o que gerou um saldo de gols negativo.

Para concluir as análises, nas Tabelas VI e VII, são apresentados os resultados alcançados das partidas realizadas contra o time RobotBulls. Especificamente, a Tabela VI apresenta os resultados das partidas entre o time UFRBots2D-2022 e o time RobotBulls. Já a Tabela VII, por sua vez, descreve os resultados das partidas entre o time UFRBots2D-2021 e o time RobotBulls.

Tabela VI: Resultados das partidas entre UFRBots2D-2022 X RobotBulls.

UFRBots	RobotBulls	SG
3	2	1
2	0	2
2	2	0
3	1	2
5	1	4
4	1	3
2	0	2
2	3	-1
2	3	-1
3	0	3
28	13	15

Tabela VII: Resultados das partidas entre UFRBots2D-2021 X RobotBulls.

UFRBots	RobotBulls	SG
9	2	7
1	1	0
4	0	4
0	1	-1
4	1	3
4	1	3
2	1	1
3	0	3
1	1	0
1	0	1
29	8	21

Como pode ser observado na Tabela VI, de 10 partidas realizadas contra o time RobotBulls, a UFRBots2D conseguiu um total de 7 vitórias e duas uma derrotas, com bons resultados em saldo de gols. Avaliando a Tabela VII e realizando uma comparação com os resultados exibidos na Tabela VI, observa-se que das 10 partidas realizadas o time UFRBots2D-2021 alcançou 7 vitórias. O rendimento do time resultou ainda em 2 empates e 1 derrota contra o time RobotBulls.

Em resumo, o time UFRBots-2022 obteve resultados superiores ao time do ano anterior, o UFRBots-2021. Dessa forma, a Tabela VII demonstra a comparação dos times em relação a aspectos número de vitórias, derrotas e empates e como saldo de gols, reiterando assim, o cumprimento do objetivo inicial desse TDP.

Tabela VIII: Comparação geral dos resultados entre o UFRBots2D-2021 X UFRBots2D-2022.

Equipes	Vitórias	Empates	Derrotas	SG
UFRBots2D-2021	11	13	6	19
UFRBots2D-2022	15	9	6	23

Sendo assim, a Tabela VIII demonstra que o time atual, UFRBots-2022, obteve um maior número de vitórias e menor número de empates, consequentemente com um maior saldo de gols. Isto é, um time mais competitivo, que apresenta as melhorias que foram executadas durante o ano em seus resultados.

VII. CONCLUSÃO

O presente trabalho apresentou a descrição do time UFRBots2D. Neste, foi descrito a modelagem adotada para a participação na Competição Brasileira de Robótica de 2022. Neste sentido, destaca-se que a modelagem utilizada anteriormente foi mantida. Nesta, realizou-se a unificação de três seções na modelagem dos estados e a tratativa de posição do adversário mais próximo, considerando o avanço do time em relação ao gol. Para isto, foi descrita a modelagem do Aprendizado por Reforço utilizada para desenvolver o time.

O time desenvolvido apresentou bons resultados durante os experimentos. Destaca-se que dentre todas as partidas realizadas durante o experimento contra os três times utilizados como adversários, o nosso time sofreu apenas um total de 16,6% de derrotas e teve saldo de gols positivo contra todos os adversários. Esse resultado expressa o bom rendimento do time UFRBots2D.

Em trabalhos futuros espera-se evoluir o time UFRBots2D a partir da utilização de outras abordagens. Sendo que estas podem ser abordagens diferentes do AR ou ainda a aplicação de outras técnicas de Inteligência Artificial no futebol 2D.

AGRADECIMENTOS

Este trabalho foi desenvolvido dentro do contexto do projeto de pesquisa “UFRBots: Equipe de Futebol de Robôs da UFR”, com apoio da instituição, da PROEXT/UFRB (Edital PIBEX 03/2022) e do CETEC/UFRB, com código de projeto 2372, PPGCI/UFRB. Além disso, agradecemos aos desenvolvedores e instituições dos times base utilizados: *Uva Trilearn*, *Helios Base* e *UFSJ2D*.

REFERENCES

- [1] Abreu, M., Reis, L.P., and Lau, N. (2019). Learning to run faster in a humanoid robot soccer environment through reinforcement learning. In S. Chalup, T. Niemueller, J. Suthakorn, and M.A. Williams (eds.), *RoboCup 2019: Robot World Cup XXIII*, 3–15.
- [2] AKIYAMA, Hidehisa; NAKASHIMA, Tomoharu. Helios base: An open source package for the robocup soccer 2d simulation. In: *Robot Soccer World Cup*. Springer, Berlin, Heidelberg, 2013. p. 528-535.
- [3] Fabro, J., Reis, L., and Lau, N. (2015). Using reinforcement learning techniques to select the best action in setplays with multiple possibilities in robocup soccer simulation teams. In *2nd SBR Brazilian Robotics Symposium*, 85–90.
- [4] JESUS, H. S.; JESUS, J. A. M. P.; SANTOS, A.; OTTONI, A. L. C.; BITTENCOURT, J. C. N.; ROCHA, P. F. F. Metodologia Extensionista para o Ensino de Futebol de Robôs. XXIII Congresso Brasileiro de Automática de Automática (CBA), 2020.
- [5] JESUS, H. S.; OTTONI, A. L. C. Desenvolvimento de uma Interface Gráfica Didática para o Ensino de Aprendizado por Reforço com Futebol de Robôs. XXIII Congresso Brasileiro de Automática de Automática (CBA), 2020.
- [6] Kitano, H., Asada, M., Kuniyoshi, Y., Noda, I., Osawa, E., and Matsubara, H. (1997). Robocup: A challenge problem for ai. *AI Magazine*, 18(1), 73–85.
- [7] KOK, Jelle R. et al. UvA Trilearn 2003 team description. *Proceedings CD RoboCup*, v. 2003, 2003.
- [8] MARTINS, M. F. Aprendizado por reforço acelerado por heurísticas aplicado ao domínio do futebol de robôs. Dissertação (Mestrado) — Centro Universitário da FEI, 2007.
- [9] OTTONI, A. L. C. Análise de sensibilidade dos parâmetros do aprendizado por reforço na solução do problema do caixeiro viajante. Dissertação (Mestrado) — Universidade Federal de São João del-Rei, 2016.
- [10] OTTONI, Andre Luiz C. et al. UFSJ2D (UaiSoccer2D + RoboCap): Team Description Paper Robocup 2014.
- [11] OTTONI, Andre Luiz C. et al. Uma Revisão sobre Tecnologias Aplicadas ao Futebol de Robôs. XXIII Congresso Brasileiro de Automática de Automática (CBA), 2020.
- [12] OTTONI, A. L. C.; NEPOMUCENO, E. G.; OLIVEIRA, M. S. d. Análise de sensibilidade dos parâmetros do aprendizado por reforço na solução do problema do caixeiro viajante: modelagem via superfície de resposta. In: CONGRESSO BRASILEIRO DE AUTOMÁTICA. [S.l.: s.n.], 2016. v. 21, p. 513–518.
- [13] OTTONI, A. L. C. ; NEPOMUCENO, E. G. ; OLIVEIRA, M. S. ; LAMPERTI, R. D. . Análise do Aprendizado por Reforço Aplicado a Otimização em Tomadas de Decisões Multiagente. In: 1st BRICS Countries Congress (BRICS-CCI) and 11th Brazilian Congress (CBIC) on Computational Intelligence, 2013, Porto de Galinas - PE. Anais do 1st BRICS Countries Congress (BRICS-CCI) and 11th Brazilian Congress (CBIC) on Computational Intelligence, 2013.
- [14] PELLEGRINI, J.; WAINER, J. Processos de decisão de markov: um tutorial. *Revista de Informática Teórica e Aplicada*, v. 14, n. 2, p. 133–179, 2007.
- [15] RUSSELL, S. J.; NORVIG, P. Inteligência artificial. [S.l.]: Campus, 2013.

- [16] SANTOS, Kevin L. dos et al. CONGRESSO BRASILEIRO DE EXTENSÃO UNIVERSITÁRIA, 9., 2020, Belo Horizonte. Metodologia extensionista para o ensino de sistemas microcontrolados. CBEU, 2021.
- [17] SUTTON, R. S.; BARTO, A. G. Reinforcement learning: An introduction. [S.l.]: MIT press, 2018.
- [18] WATKINS, C. J. C. H. Learning from delayed rewards. Tese (Doutorado) — University of Cambridge, 1989.
- [19] WATKINS, C. J. C. H. Technical note q-learning. Reinforcement learning, 1993.